

BENCHMARK DE MODÈLES D'EXTRACTION ET DE RÉOLUTION D'ENTITÉS NOMMÉES

Étude expérimentale reproductible sur des transcriptions issues de speech-to-text

Auteur	Besim Berisha
Date	Octobre 2026
Corpus expérimental	30 transcriptions
Licence du code	MIT

Code source : github.com/BessIm/ner-benchmark

Portée du rapport

Le dépôt et la méthode sont génériques. Les exemples sont fictifs et aucun nom réel issu du corpus expérimental n'est reproduit. Les données sources ne sont pas distribuées avec le code.




Figure 1 - Volume total d'occurrences détectées par modèle. Le volume ne constitue pas une mesure de précision.

Résumé exécutif

Cette étude compare cinq modèles d'intelligence artificielle capables de repérer automatiquement, dans 30 transcriptions, des noms de personnes, d'organisations, de lieux et d'événements. Une seconde expérimentation cherche ensuite à repérer les différentes écritures qui pourraient désigner une même entité, par exemple lorsqu'un nom propre est transcrit de plusieurs façons.

Le benchmark NER indique que SauerkrautLM-GLiNER est le candidat le plus intéressant pour poursuivre l'étude : il détecte le plus grand nombre de mentions dans les quatre catégories demandées, tout en conservant des scores internes élevés et un temps de traitement proche de GLiNER Multi. Cela ne prouve pas encore qu'il est le modèle le plus juste : sans corpus entièrement vérifié par des humains, on ne peut pas mesurer sa précision réelle ni son taux de détection.

L'étude des variantes d'écriture montre qu'une fusion entièrement automatique est trop risquée. La ressemblance entre les noms, leur proximité phonétique et le contexte dans lequel ils apparaissent apportent des indices utiles, mais ils peuvent aussi rapprocher à tort deux personnes différentes. La méthode recommandée consiste donc à proposer au professionnel de la documentation les correspondances les plus probables, sans décider à sa place.

Dans l'architecture cible, les entités confirmées par un humain sont conservées dans un référentiel interne avec leurs différentes variantes d'écriture. Elles peuvent ensuite être reliées à un référentiel d'autorité, par exemple IdRef, Wikidata, VIAF ou un référentiel métier. La décision documentaire finale reste humaine.

Décision proposée
Pour l'extraction : SauerkrautLM-GLiNER est retenu comme candidat principal. Pour les variantes d'écriture : le système combine ressemblance du nom, proximité phonétique et contexte afin de proposer des correspondances, mais celles-ci doivent être validées par un humain. Après validation, l'entité peut être reliée à IdRef ou à tout autre référentiel adapté.

1. Objectif et vocabulaire

Extraction d'entités nommées (NER) - Technique consistant à repérer dans un texte des éléments qui correspondent à des catégories d'entités, par exemple une personne, une organisation ou un lieu. Dans ce rapport, le NER repose principalement sur des modèles d'intelligence artificielle.

Entité et mention - Une entité est la personne, l'organisation, le lieu ou l'événement que l'on souhaite identifier. Une mention est simplement la façon dont cette entité apparaît dans le texte. Par exemple, une même personne peut être mentionnée sous plusieurs écritures différentes.

Score de confiance - Valeur produite par le modèle pour indiquer à quel point sa détection lui paraît plausible. Un score de 0,95 ne signifie pas qu'il a 95 % de chances d'avoir raison : ce score n'est pas une mesure de précision tant qu'il n'a pas été comparé à des validations humaines.

Ressemblance d'écriture (fuzzy matching) et phonétique - Le fuzzy matching mesure à quel point deux écritures se ressemblent, même si elles ne sont pas identiques. La comparaison phonétique cherche à savoir si elles peuvent se prononcer de façon proche. Ces deux méthodes sont des algorithmes classiques, pas des modèles d'intelligence artificielle.

Embedding - Un embedding est une représentation numérique d'un texte produite par un modèle d'IA. Deux contextes proches obtiennent des représentations proches. Ici, cette technique sert à comparer les phrases qui entourent deux noms afin de voir s'ils apparaissent dans des situations similaires.

Résolution d'entités (Entity Resolution) et rattachement à un référentiel (Entity Linking) - La résolution cherche à savoir si plusieurs écritures pourraient désigner la même entité réelle. Une fois cette entité validée, l'Entity Linking consiste à la rattacher à une notice existante dans un référentiel d'autorité, par exemple IdRef, Wikidata ou VIAF.

Jeu de référence validé humainement (gold standard) - Ensemble de textes pour lesquels des humains ont indiqué ce qui est correct. Il sert de vérité de référence pour mesurer objectivement la qualité d'un modèle. Il n'était pas encore disponible pendant cette étude exploratoire.

2. Périmètre expérimental

Corpus - Le corpus comprend 30 transcriptions. Les fichiers JSON peuvent contenir des segments, des mots horodatés ou des scores, mais le benchmark NER utilise exclusivement la propriété text, c'est-à-dire la transcription complète.

Fenêtrage - Les transcriptions sont traitées par fenêtres afin de respecter les limites de longueur propres aux modèles. Un chevauchement évite de perdre une entité située à une frontière. Les doublons issus du chevauchement sont ensuite supprimés.

3. Méthodologie et environnement

Les cinq modèles sont exécutés localement, dans des scripts séparés mais suivant le même principe général : lecture de text, découpage en fenêtres, extraction des mentions, normalisation des libellés et export des résultats.

Modèle	Nature	Classes / labels	Fenêtre
CamemBERT	IA - NER supervisé	PER / ORG / LOC / MISC	5000 / 500
ModernCamemBERT	IA - NER supervisé	LOC / PER / ORG / MISC	5000 / 500
GLiNER Multi v2.1	IA - NER multilingue, labels libres	personne / organisation / lieu / événement	1500 / 200
GLiNER Large v2.5	IA - NER, variante large	personne / organisation / lieu / événement	1500 / 200
SauerkrautLM-GLiNER	IA - NER multilingue	person / organization / location / event	1500 / 200

Les tailles de fenêtre GLiNER ont été ramenées à 1500 caractères avec 200 caractères de chevauchement afin d'éviter la limite de 384 tokens rencontrée dans la configuration initiale. Les résultats GLiNER utilisés dans ce rapport proviennent de la configuration corrigée.

Configuration matérielle de référence

Élément	Configuration
Système	Ubuntu / Linux
Python	3.14.4
PyTorch	2.14.0+cu132
CUDA	Disponible
GPU	NVIDIA RTX PRO 5000 Blackwell
VRAM détectée	47.3 Go

La puissance GPU sert principalement à réduire le temps d'inférence. La configuration de référence n'est pas une exigence minimale : les scripts détectent automatiquement CUDA et peuvent fonctionner sur CPU, avec des temps plus élevés.

4. Reproductibilité et dépôt de code

Les scripts, la méthodologie et un exemple de transcription fictive sont publiés sous licence MIT dans le dépôt : github.com/Besslm/ner-benchmark. Les données expérimentales réelles ne sont pas distribuées avec le dépôt. Les poids des modèles ne sont pas inclus et restent soumis à leurs propres licences.

5. Résultats du benchmark NER

Le tableau ci-dessous compte chaque apparition détectée. Si un même nom apparaît dix fois, il est compté dix fois. Ces volumes permettent de comparer le comportement des modèles, mais ils ne correspondent ni à un nombre de personnes réelles ni à une mesure de précision.

Modèle	Total	Personnes	Organisations	Lieux	Événements	Temps (s)
CamemBERT	22 690	8 292	3 600	7 220	0	12.4
GLiNER Multi v2.1	41 795	18 725	9 324	11 271	2 475	69.6
GLiNER Large v2.5	37 329	17 050	7 423	9 490	3 366	129.8
ModernCamemBERT	32 552	6 244	1 372	13 657	0	32.9
SauerkrautLM-GLiNER	51 234	19 669	11 337	13 373	6 855	64.7




Figure 2 - Répartition des occurrences par catégorie. Les volumes ne mesurent pas directement la qualité.

Sur ce corpus, SauerkrautLM-GLiNER détecte le plus grand nombre de mentions dans chacune des quatre catégories demandées : 19 669 apparitions classées PERSONNE, 11 337 ORGANISATION, 13 373 LIEU et 6 855 EVENEMENT. Ces valeurs comptent les répétitions : une même personne citée plusieurs fois augmente donc le total.

Comment lire ce tableau

Un modèle qui trouve davantage de mentions peut réellement en manquer moins, mais il peut aussi produire davantage d'erreurs. À ce stade, le tableau indique surtout le comportement des modèles. Il ne permet pas encore d'affirmer qu'un modèle est plus précis qu'un autre.

6. Occurrences, mentions uniques et confiance interne

Modèle	Détections totales	Formes différentes	Répétition moyenne	Score moyen	Score médian	Fragments 1-2 car.
CamemBERT	22690	14393	1.58×	0.906	0.984	628
GLiNER Multi v2.1	41795	20884	2.00×	0.755	0.794	283
GLiNER Large v2.5	37329	19846	1.88×	0.793	0.844	123
ModernCamemBERT	32552	19539	1.67×	0.639	0.613	2207
SauerkrautLM-GLiNER	51234	26785	1.91×	0.880	0.942	270

Exemple de lecture : Sauerkraut produit 51 234 détections au total. Après suppression des répétitions textuellement identiques à l'intérieur des transcriptions, il reste 26 785 formes différentes. Cela ne signifie pas qu'il existe 26 785 entités réelles : plusieurs écritures différentes peuvent encore désigner la même personne, le même lieu ou la même organisation.

Les scores internes donnent une indication sur l'assurance du modèle, mais pas sur sa justesse réelle. Sauerkraut obtient une médiane de 0,942 et CamemBERT de 0,984. Cela signifie seulement que CamemBERT attribue souvent des scores très élevés aux détections qu'il conserve ; il faut des validations humaines pour savoir si ces détections sont effectivement correctes.

Les détections d'un ou deux caractères sont utilisées ici comme indicateur simple de bruit potentiel : beaucoup de fragments très courts peuvent signaler un comportement instable. Sauerkraut en produit 270, contre 2 207 pour ModernCamemBERT. Ce n'est qu'un signal d'alerte, pas une mesure complète de qualité.




Figure 3 - Temps d'inférence cumulé sur les 30 transcriptions, sur la configuration matérielle de référence.

7. Analyse comparative et choix du candidat NER

CamemBERT. Modèle français supervisé utilisé comme baseline. Il est rapide (12,4 s) et très confiant sur les occurrences retenues, mais son volume de personnes et d'organisations est nettement inférieur à celui des GLiNER.

ModernCamemBERT. Son comportement est particulièrement conservateur pour PERSONNE et ORGANISATION, tandis qu'il produit beaucoup de MISC et de mentions très courtes. Il ne présente pas, sur ce corpus, un avantage suffisant pour justifier sa sélection comme modèle principal.

GLiNER Multi v2.1. Il combine un volume important, des catégories définies directement par l'utilisateur et un temps raisonnable. Il constitue une bonne baseline pour les approches à labels libres.

GLiNER Large v2.5. Il est plus lent (129,8 s) que GLiNER Multi et Sauerkraut, sans gain évident suffisant sur ce corpus. Il reste cependant le modèle le plus strict parmi les GLiNER selon l'indicateur des mentions très courtes.

SauerkrautLM-GLiNER. Il obtient les plus gros volumes dans chacune des quatre catégories demandées, avec 51 234 occurrences au total et 64,7 s d'inférence. Il devient donc le candidat principal de l'étape de résolution.

Choix retenu pour la suite
SauerkrautLM-GLiNER est retenu comme candidat NER principal sur la base du benchmark exploratoire. Cette décision doit être confirmée par une évaluation sur gold standard avant de parler de « meilleur modèle » au sens statistique.

8. Résolution des variantes - première expérience

Après l'extraction, une seconde question se pose : que faire lorsque le même nom semble avoir été écrit de plusieurs façons ? Cette première expérience cherche à rapprocher les formes classées PERSONNE par Sauerkraut afin d'identifier des variantes possibles, sans considérer ces rapprochements comme des vérités.

Plusieurs stratégies ont été comparées : égalité exacte après nettoyage, ressemblance d'écriture à différents niveaux de tolérance, proximité phonétique et comparaison par modèle d'IA. Les réglages trop permissifs créent un effet de chaîne : un nom ressemble à un deuxième, le deuxième à un troisième, et le système finit par fusionner des personnes qui ne sont pas nécessairement identiques.

Approche	Résultat observé	Décision
Fuzzy 75-90	Réduction extrême du nombre de groupes ; très gros clusters	Rejetée pour fusion automatique
Fuzzy 95	Rapprochements plus prudents mais encore des fusions ambiguës	Candidat pour génération
Phonétique	Capture des variantes sonores, mais dépend du candidat initial	À combiner
Embeddings sur les noms	Regroupements sémantiques excessifs sur des noms propres	Rejetée seule
Fuzzy + phonétique	Amélioration, mais fusions encore trop agressives	À encadrer

Conclusion de cette première expérience : une forte ressemblance constitue un bon motif pour proposer une vérification, mais elle ne constitue jamais, à elle seule, une preuve que deux noms désignent la même personne.

9. Résolution contextuelle - expérience finale

L'expérience finale repart des 19 669 mentions classées PERSONNE par le NER. Comme un même nom peut apparaître plusieurs fois, ces mentions se ramènent à 8 152 écritures différentes sur l'ensemble du corpus. Ce nombre ne représente pas 8 152 personnes : plusieurs écritures peuvent désigner la même personne, et certaines détections peuvent aussi être erronées. Pour chaque écriture, le système retient jusqu'à cinq correspondances possibles et les classe en combinant trois indices : ressemblance du nom, proximité phonétique et similarité du contexte calculée par le modèle d'IA BAAI/bge-m3.

Exemple fictif

Si « Sophie Durand » apparaît 12 fois, « Sofie Durand » 4 fois et « Sophie Durant » 3 fois, cela représente 19 occurrences mais seulement 3 écritures différentes. Après validation humaine, ces trois écritures pourraient éventuellement être rattachées à une seule personne réelle.

Indicateur	Valeur	Comment le lire
Mentions classées PERSONNE	19 669	Nombre total d'apparitions détectées ; les répétitions sont comptées.
Écritures différentes	8 152	Après déduplication exacte. Ce n'est pas un nombre de personnes réelles.
Comparaisons de candidats	36 984	Nombre de paires de noms jugées assez plausibles pour être comparées plus finement.
Groupe proposés prudemment	409	Groupe de variantes possibles à soumettre à validation humaine ; ils ne sont pas validés.
Taille du plus grand groupe	17	Nombre maximal d'écritures rassemblées dans une même proposition de groupe.
Temps de traitement	123.2 s	Temps nécessaire pour l'expérience complète sur la machine de référence.
Même meilleur candidat pour les 3 méthodes	38.4 %	Part des cas où écriture, phonétique et contexte aboutissent au même choix.
Modèle IA utilisé pour le contexte	BAAI/bge-m3	Modèle d'embeddings servant uniquement à comparer le contexte autour des noms.

Dans seulement 38,4 % des cas, les trois méthodes choisissent exactement le même meilleur candidat. Autrement dit, l'écriture, la prononciation et le contexte ne conduisent souvent pas à la même conclusion. C'est précisément pourquoi une fusion automatique serait risquée. La combinaison écriture + phonétique rejoint le choix fondé sur le contexte dans 69,1 % des cas ; le contexte change donc encore le classement dans environ trois cas sur dix.

Résultat principal de l'expérience finale

Le système est utile pour réduire la liste des possibilités et présenter les candidats les plus plausibles. En revanche, même avec le contexte, il n'est pas assez fiable pour décider seul que deux écritures désignent la même personne. La validation humaine reste donc une étape obligatoire.

Source du modèle de contexte : [BAAI/bge-m3](#) (licence MIT).

10. Architecture cible

L'architecture proposée sépare clairement ce que la machine peut préparer de ce que l'humain doit décider. Le modèle d'IA repère des noms dans la transcription ; les méthodes de rapprochement cherchent des variantes possibles ; le catalogueur confirme ensuite l'identité réelle et, si nécessaire, la relie à un référentiel d'autorité.

Étape	Composant	Rôle
1	Speech-to-text	Production de la transcription
2	NER - modèle IA	Détection de PERSONNE, ORGANISATION, LIEU, EVENEMENT
3	Nettoyage et alias connus	Uniformisation simple des écritures et reconnaissance des variantes déjà validées

Étape	Composant	Rôle
4	Recherche de correspondances possibles	Ressemblance du nom + phonétique + contexte calculé par IA
5	Validation humaine	Confirmation, correction, séparation ou création
6	Entité validée dans le référentiel interne	Identifiant stable associé aux différentes variantes approuvées
7	Référentiel d'autorité	IdRef dans le cas d'usage ; autre référentiel possible
8	Indexation	Utilisation de l'entité validée pour la recherche

Principe de gouvernance

L'IA ne remplace pas l'autorité documentaire. Elle prépare et hiérarchise les propositions. Le catalogueur reste responsable de la validation de l'entité canonique et de son rattachement à un référentiel d'autorité.

Dans ce scénario, les variantes validées deviennent des alias connus. Une nouvelle occurrence identique à un alias validé peut alors être rattachée directement à l'entité interne, sans refaire l'intégralité du calcul de similarité.

11. Limites et protocole d'évaluation futur

La principale limite de cette étude est l'absence, à ce stade, d'un ensemble complet de réponses validées par des humains. Les nombres de détections, les scores internes et les regroupements automatiques décrivent le comportement du système, mais ils ne suffisent pas à dire combien de résultats sont réellement corrects.

La prochaine étape consiste à faire contrôler par des catalogueurs un échantillon représentatif : différentes catégories d'entités, détections jugées très sûres ou moins sûres, ainsi que des cas où les modèles sont d'accord ou en désaccord. Ces validations constitueront progressivement le jeu de référence nécessaire à une mesure objective.

Une fois ce jeu de référence disponible, on pourra mesurer la précision (parmi les résultats proposés, quelle proportion est correcte), le rappel (parmi les entités réellement présentes, quelle proportion a été retrouvée) et le score F1, qui résume l'équilibre entre les deux. Pour le rattachement, on pourra aussi mesurer à quelle fréquence la bonne entité est proposée en première position ou au moins parmi les premiers candidats.

Phase	Objectif	Statut
Benchmark NER sur 30 transcriptions	Sélection exploratoire du modèle	Terminé
Résolution exploratoire	Éliminer les méthodes trop agressives	Terminé
Résolution contextuelle	Proposer des candidats mieux classés	Terminé
Validation par les catalogueurs	Confirmer/corriger les propositions et constituer le jeu de référence	À mettre en place
Rattachement au référentiel	Associer les entités validées à IdRef ou autre référentiel	À mettre en place
Évaluation chiffrée	Mesurer précision, rappel, F1 et qualité du rattachement	À venir

Cette démarche permet aussi d'éviter un biais de sélection : si un modèle semble plus « généreux » avant annotation, on ne suppose pas qu'il est meilleur ; on mesure ensuite quelle proportion de ses propositions s'avère réellement utile.

12. Reproductibilité, licences et références

Dépôt de code : github.com/BessIm/ner-benchmark - licence MIT. Les scripts sont destinés à être réutilisés sur d'autres corpus de transcriptions.

Modèles NER

- CamemBERT NER - <https://huggingface.co/Jean-Baptiste/camembert-ner>
- Moderncamembert_4entities - https://huggingface.co/CATIE-AQ/Moderncamembert_4entities
- GLiNER Multi v2.1 - https://huggingface.co/urchade/gliner_multi-v2.1
- GLiNER Large v2.5 - https://huggingface.co/gliner-community/gliner_large-v2.5
- SauerkrautLM-GLiNER - <https://huggingface.co/VAGOsolutions/SauerkrautLM-GLiNER>

Modèle d'embeddings

<https://huggingface.co/BAAI/bge-m3>

Référence méthodologique GLiNER

Zaratiana et al., « GLiNER: Generalist Model for Named Entity Recognition using Bidirectional Transformer », arXiv:2311.08526 - arxiv.org/abs/2311.08526

Configuration de référence

Ubuntu/Linux ; Python 3.14.4 ; PyTorch 2.14.0+cu132 ; NVIDIA RTX PRO 5000 Blackwell ; 47.3 Go de VRAM ; CUDA disponible.

Reproductibilité des données

Le dépôt fournit un exemple fictif de transcription. Les transcriptions expérimentales réelles et les résultats détaillés contenant des mentions ne sont pas publiés. Les poids des modèles sont téléchargés séparément auprès de leurs sources.

Annexe - Exemples fictifs

Les exemples suivants sont entièrement fictifs. Ils illustrent les mécanismes décrits dans l'étude sans reproduire aucune entité du corpus expérimental.

Exemple 1 - NER

Transcription : « Sophie Durand s'est rendue à Montfleury pour rencontrer les représentants de l'Association Horizon. »

Extraction attendue : Sophie Durand → PERSONNE ; Montfleury → LIEU ; Association Horizon → ORGANISATION.

Exemple 2 - variantes

Les mentions « Sophie Durand », « Sofie Durand », « Sophie Durant » et « Mme Durand » peuvent être proposées comme variantes candidates. Elles ne doivent pas être fusionnées automatiquement sans validation.

Exemple 3 - référentiel

Après validation humaine : « Sophie Durand » → identifiant interne P00123 → identifiant du référentiel d'autorité choisi. Dans le cas d'usage étudié, ce dernier pourrait être un identifiant IdRef.

Exemple 4 - faux rapprochement

« Alex Martin », « Alexandre Martin » et « Alex Martel » présentent une ressemblance suffisante pour justifier une proposition de vérification, mais pas une fusion automatique.

Conclusion opérationnelle
Le système recommandé transforme le NER et la résolution d'entités en outils d'assistance au catalogage : détection, regroupement prudent, présentation de candidats et validation humaine.